

第7章 支持向量机

7.1 线性可分支持向量机 & 硬间隔最大化

假设空间:

$$w \cdot x + b = 0$$

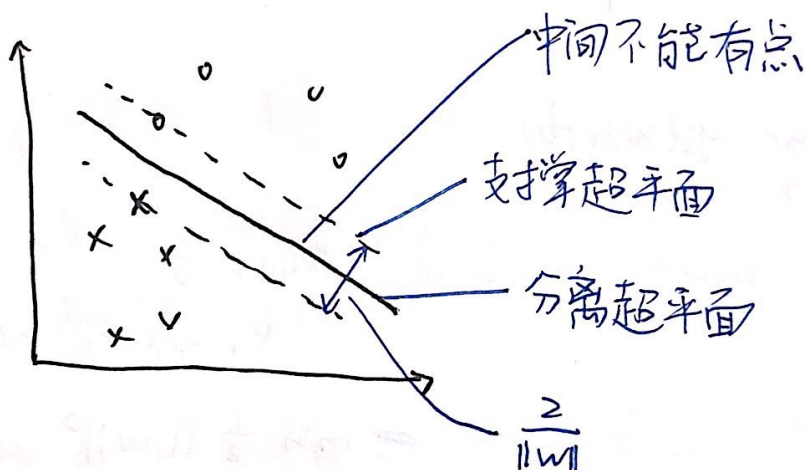
决策函数

$$f(x) = \text{sgn}(w^* \cdot x + b^*) \begin{cases} +1 \\ -1 \end{cases}$$

模型选择依据 (SVM 超平面唯一)

(感知机 ~ 不唯一)

硬间隔最大化




函数距离 $|w \cdot x^* + b|$

几何距离 $\frac{|w \cdot x^* + b|}{\|w\|}$

} 求点 x^* 到分离超平面的距离

为什么得用几何距离, 而不能用函数距离呢?



若是函数距离 则为 $|0+0-1|=1$

会因为系数产生改变. $|0+0+2|=2$

$\therefore X$

总结: 衡量一个点到不同的超平面用几何距离

不能用函数距离

衡量不同的点到一个给定的超平面

可用函数距离

模型选择依据

石更间隔最大化

① $\frac{|w \cdot x + b|}{\|w\|} \Rightarrow \frac{y_i (w \cdot x_i + b)}{\|w\|}$

去掉绝对值方法

② $\max_{w,b} \min_i \frac{y_i (w \cdot x_i + b)}{\|w\|}$

距离

~~先找到到超平面最小的点~~

先找最小的点再让这个点到超平面的距离最大

③ $\max_{w,b} \frac{1}{\|w\|} \min_i y_i (w \cdot x_i + b)$

为了使求解 $\min_i y_i (w \cdot x_i + b)$ 简单, 我们认为

$$y_i (w \cdot x_i + b) \geq 1$$

接着, 找 $\max_{w,b} \frac{1}{\|w\|}$ 等价于求 $\min \frac{1}{2} \|w\|^2$

④ 最小化问题

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$\text{s.t. } y_i (w \cdot x_i + b) - 1 \geq 0$$

$i=1, 2, \dots, N$

对偶问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i=1, 2, \dots, N$$

KKT

$$\begin{cases} w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \\ b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \end{cases}$$

可以~~删~~让原问题转为对偶问题, 求得 α .

再用 KKT 求出原问题的最优解 w^*, b^*

$$\frac{w^* \cdot x}{x_i \cdot x} + \frac{b^*}{x_i \cdot x_j} = 0$$

7.2 线性支持向量机与软间隔最大化

提出意义 } ① 若原数据集是线性不可分的.

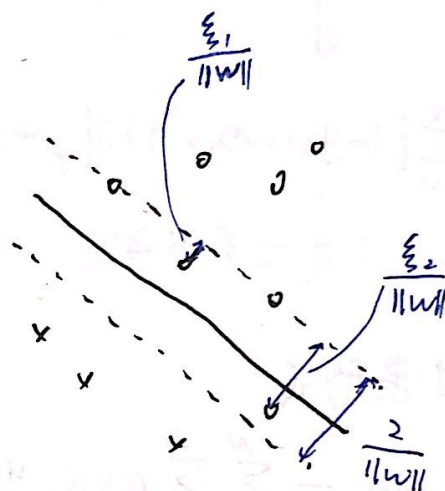
② 支持向量对硬间隔中的分离超平面起着决定性因素, 要削弱这个影响.

最优化问题.

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t. } y_i(w \cdot x_i + b) \geq 1 - \xi_i, \quad i=1, 2, \dots, N$$

$$\xi_i \geq 0, \quad i=1, 2, \dots, N$$



理解: 间隔之间也可以出现点, 但是要对他们进行惩罚.

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$


表示最小化越界的点

表示最大化超平面间隔

在这两个之间做出权衡

那我们如何表示这个惩罚呢?

用 合页损失函数



原问题

$$\frac{1}{2} \|w\|^2 + C \sum_i \xi_i$$

↓

$$\sum_{i=1}^N [1 - y_i(w \cdot x_i + b)]_+ + \lambda \|w\|^2$$

λ 由 C 与 $\frac{1}{2}$ 共同决定

代入

$$\xi_i = \begin{cases} 1 - y_i(w \cdot x_i + b) & \text{if } 1 - y_i(w \cdot x_i + b) > 0 \\ 0 & \text{otherwise} \end{cases}$$

$$\xi_i = \max(0, 1 - y_i(w \cdot x_i + b))$$

对偶形式

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0$$

$$0 \leq \alpha_i \leq C, \quad i=1, 2, \dots, N$$



KKT

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$b^* = y_j - \sum_{i=1}^N y_i \alpha_i^* (x_i \cdot x_j)$$

7.3 非线性支持向量与核函数

问题: 不知道用什么曲面



$$x^{(1)2} + x^{(2)2} \quad \text{让 } z = \varphi(x), \quad z^{(1)} = x^{(1)2}, \quad z^{(2)} = x^{(2)2}$$

$$x_i \cdot x_j \Rightarrow \underline{K(x_i, x_j)} = \varphi(x_i) \cdot \varphi(x_j)$$

好处: 核函数

不用写出 φ 具体的形式, 只用写出 K 的形式即可

原问题 将 $x \rightarrow \varphi(x)$

$$\min \frac{1}{2} \|w\|^2 + C \sum \xi_i$$

$$\text{s.t. } y_i [w \cdot \varphi(x)] \geq 1 - \xi_i$$

$$\xi_i \geq 0$$

分离超平面: $w \cdot \varphi(x) + b = 0$

对偶问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i=1, 2, \dots, N$$

决策函数

$$f(x) = \text{sign} \left[\sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b^* \right]$$

7.4 序列最小优化算法

背景: 7.3 是最普通的形式, 如果

$$\left\{ \begin{array}{l} \text{为 7.1} \\ \text{① } c \rightarrow \infty, K(x_i, x_j) = x_i \cdot x_j \\ \text{为 7.2} \\ \text{② } K(x_i, x_j) = x_i \cdot x_j \end{array} \right.$$

对偶问题

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq c, \quad i=1, 2, \dots, N.$$

理解:

我们总共要优 N 个 α , 但是同时优化 N 个 α 难度太大,

那么如果一个优化一个 α 的话, 可以吗?

$$\text{不行. } \because \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_1 = \frac{-\sum_{i=2}^N \alpha_i y_i}{y_1} \quad \alpha_1 \text{ 由其它 } N-1 \text{ 个 } \alpha \text{ 决定}$$

一次
 \therefore 不能优化一个

因此出现了给定 α 初值, 一次优化 (α_1, α_2) 2 个 α , 直到收敛. 具体看书

软间隔最大化对偶问题

推导过程

这是个凸优化问题

$$\textcircled{1} \min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.t. } y_i(w \cdot x_i + b) \geq 1 - \xi_i, i=1, \dots, N$$

$$\xi_i \geq 0, i=1, \dots, N$$

w 是唯一的 (即分离超平面斜率唯一)

b 是不唯一的 ($\because \xi_i$ 的解也不唯一, 但是 $\sum \xi_i$ 是唯一的)

② 写出拉格朗日函数

根据拉格朗日概念

凸优化问题的对偶形式

的最优解与原问题最优解一致, 且满足 KKT 条件

$$L(w, b, \xi, \alpha, u) = \frac{1}{2} \|w\|^2 + C \sum \xi_i +$$

$$\sum \alpha_i [1 - \xi_i - y_i(w \cdot x_i + b)] +$$

$$\sum u_i (-\xi_i)$$

$$= \frac{1}{2} \|w\|^2 + C \sum \xi_i - \sum \alpha_i [y_i(w \cdot x_i + b) - 1 + \xi_i] - \sum u_i \xi_i$$

如何写出拉格朗日函数

① L (关于那些变量, 有几个约束条件就有几个拉格朗日乘子) =

② 最小化函数照抄 + \sum_i 拉格朗日乘子 \times 约束条件

约束条件一定要写成 小于等于 0 形式

如: $1 - \xi_i - y_i(w \cdot x_i + b) \leq 0$

③ 整理

③ 写出对偶问题

① 用拉格朗日函数分别对参数求导，再让其=0

$$L(w, b, \xi, \alpha, u) = \frac{1}{2} \|w\|^2 + C \sum \xi_i - \sum \alpha_i [y_i (w \cdot x_i + b) - 1 + \xi_i] - \sum u_i \xi_i$$

$$\nabla_w L = w - \sum \alpha_i \cdot y_i \cdot x_i = 0 \Rightarrow w = \sum \alpha_i \cdot y_i \cdot x_i$$

$$\nabla_b L = -\sum \alpha_i y_i = 0$$

$$\nabla_{\xi_i} L = C - \alpha_i - u_i = 0$$

2) 代入原问题的最大函数，即代入之前写的拉格朗日函数

$$L = \frac{1}{2} (\sum \alpha_i y_i x_i) \cdot (\sum \alpha_i y_i x_i) + C \sum \xi_i$$

$$- (\sum \alpha_i y_i x_i) (\sum \alpha_i y_i x_i) - b \sum \alpha_i y_i + \sum \alpha_i - \sum \alpha_i \xi_i$$

整理得 (根据3个求导的式子来整理) $-\sum u_i \xi_i$

$$L = -\frac{1}{2} (\sum \alpha_i y_i x_i) (\sum \alpha_i y_i x_i) + \sum \alpha_i$$

(令没了，所以最大化的问题是对 α_i 求解)

↳ 对偶问题 $\max_{w, u} \min L$

$$\therefore (\sum_i \alpha_i y_i x_i) (\sum_j \alpha_j y_j x_j)$$

$$= \sum_i \sum_j \alpha_i \alpha_j y_i y_j x_i x_j$$

∴ 关于 α 的最大化问题 ~~即~~ 变为 (拉格朗日形式) 即

$$\max_{\alpha} -\frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j x_i x_j + \sum \alpha_i$$

$$\text{s.t.} \quad \sum \alpha_i y_i = 0 \quad \alpha_i \geq 0$$

$$C - \alpha_i - u_i = 0 \quad u_i \geq 0$$

(4) 写出 KKT 形式.

$$\begin{cases} \nabla_w L = w - \sum d_i y_i x_i = 0 \\ \nabla_b L = -\sum d_i y_i = 0 \\ \nabla_{\xi_i} L = C - d_i - u_i = 0 \end{cases}$$

$$\begin{cases} d_i [y_i (w \cdot x_i + b) - 1 + \xi_i] = 0 \\ u_i \xi_i = 0 \end{cases}$$

$$\begin{cases} y_i (w \cdot x_i + b) - 1 + \xi_i \geq 0 \\ \xi_i \geq 0 \end{cases}$$

$$\begin{cases} d_i \geq 0 \\ u_i \geq 0 \end{cases}$$

$$(*d, *w) \quad (*d, *w)$$

$$d = *d \quad *w = w$$

$$\frac{*d + *d}{s} = d \quad \frac{*w + *w}{s} = w$$

$$\frac{*d + *d}{s} + \frac{*w + *w}{s} = d + w$$

$$0 \leq [1 - (*d + *w)] + [1 - (*d + *w)] \cdot \frac{1}{s} =$$

最大间隔分离超平面存在唯一性

前提: 训练数据集 T 线性可分.

① 最大间隔分离超平面是由优化问题得到的.

$$\min \frac{1}{2} \|w\|^2$$

$$\text{s.t. } y_i(w \cdot x_i + b) - 1 \geq 0$$

存在唯一性 即上面优化问题的解是存在且唯一的

② 存在性

- 1) 线性可分 (训练数据集)
- 2) 目标函数有下界
- 3) 数据集有正类点又有负类点, $\therefore (w, b) = (0, 0)$ 不是最优解, $\therefore w^* \neq 0$

③ 唯一性 (反证法)

1) 假设有 2 个最优解

$$(w_1^*, b_1^*) \quad (w_2^*, b_2^*)$$

$$\text{让 } w^* = w_1^* = w_2^* \quad b_1^* = b_2^*$$

2) 由 1) 可得

step 1 $\|w_1^*\| = \|w_2^*\| = c$

$$w = \frac{w_1^* + w_2^*}{2} \quad b = \frac{b_1^* + b_2^*}{2}$$

step 2: w, b 确定了, \therefore 现在要验证 w 与 b 满不满足约束条件

$$y_i \left(\frac{w_1^* + w_2^*}{2} \cdot x_i + \frac{b_1^* + b_2^*}{2} \right) - 1$$

$$= \frac{1}{2} [y_i (w_1^* \cdot x_i + b_1^*) - 1 + y_i (w_2^* \cdot x_i + b_2^*) - 1] \geq 0$$


$\therefore w$ 与 b 在可行域里 (满足 n 个约束条件)

step 3 $\because w_1^*$ 之前被假设为最优解, 若 $\|w_1^*\| > \|w\|$ 那么 w 才是最优解
即 $\|w_1^*\| \leq \|w\|$ 假设 $w_1^* = c$

$$\text{即 } c \leq \|w\| = \left\| \frac{1}{2} w_1^* + \frac{1}{2} w_2^* \right\| \leq \frac{1}{2} \|w_1^*\| + \frac{1}{2} \|w_2^*\|$$

根据三角不等式

$$\therefore \text{有 } \left\| \frac{1}{2} w_1^* + \frac{1}{2} w_2^* \right\| = \frac{1}{2} \|w_1^*\| + \frac{1}{2} \|w_2^*\|$$



$\therefore w_1^*$ 与 w_2^* 一定是同方向的

step 4

$$\text{即 } w_1^* = \lambda w_2^* \quad \lambda \geq 0$$

(第 1 部分证明完毕)

$$\Rightarrow \underline{w_1^* = w_2^*}$$

$$\text{又有 } \|w_1^*\| = \|w_2^*\|$$

\therefore 根据之前的假设 w_1^* 与 w_2^* 都是最优解

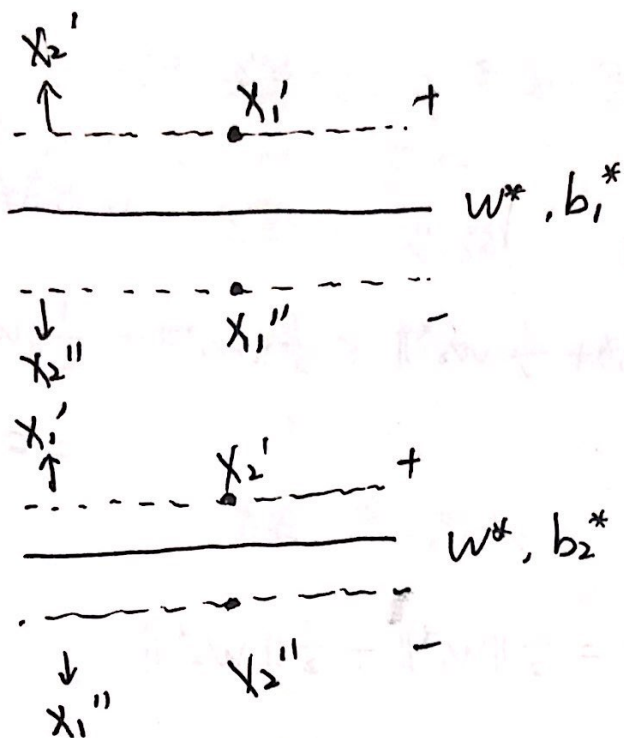
现在要证明 b 的最优解是唯一的

分析: 因为 b 出现在不等式约束中, 且证明的是唯一性问题
因此我们要从这个不等式什么时候相等入手

即位于支撑超平面上的点, 代入不等式中相等.

之前假设了 2 个最优解, 并证明了 $w_1^* = w_2^*$

\therefore 有 2 个假设空间, 如下图



$$\textcircled{1} \begin{cases} w^* \cdot x_1' + b_1^* - 1 = 0 \\ w^* \cdot x_2' + b_1^* - 1 \geq 0 \end{cases} \Rightarrow w^* \cdot x_1' \leq w^* \cdot x_2' \quad \text{--- ①}$$

$$\begin{cases} w^* \cdot x_2' + b_2^* - 1 = 0 \\ w^* \cdot x_1' + b_2^* - 1 \geq 0 \end{cases} \Rightarrow w^* \cdot x_2' \leq w^* \cdot x_1' \quad \text{--- ②}$$

由①②得

$$w^* \cdot (x_1' - x_2') = 0$$

同理

$$w^* (x_1'' - x_2'') = 0$$

③

$$\begin{cases} w^* \cdot x_1' + b_1^* - 1 = 0 \\ -[w^* \cdot x_1'' + b_1^*] - 1 = 0 \end{cases} \Rightarrow \begin{aligned} b_1^* &= 1 - w^* \cdot x_1' & \text{--- ③} \\ b_1^* &= -1 - w^* \cdot x_1'' & \text{--- ④} \end{aligned}$$

$$\frac{1}{2} \times \textcircled{3} + \frac{1}{2} \times \textcircled{4}$$

$$\Rightarrow b_1^* = -\frac{1}{2} w^* (x_1' + x_1'') \quad \text{--- ⑤} \quad \text{同理} \quad b_2^* = -\frac{1}{2} w^* (x_2' + x_2'') \quad \text{--- ⑥}$$

③ 现要证 b_1^* 与 b_2^* 相等

∴ 现在将 ⑤ - ⑥

$$\begin{aligned}\text{即 } b_1^* - b_2^* &= -\frac{1}{2} [w^* \cdot (x_1' - x_2')] \\ &\quad + (-\frac{1}{2} [w^* \cdot (x_1'' - x_2'')]) \\ &= 0\end{aligned}$$

$$\text{即 } b_1^* = b_2^*$$

$$\therefore (w_1^*, b_1^*) = (w_2^*, b_2^*)$$

得证.