

# 第9章 EM算法及其推广

## 9.1 EM算法的引入

用来估计概率分布, 但观测数据有缺失

例 9.1 三硬币模型

不完全数据

完全数据

$$z \sim b(1, \pi)$$

$\downarrow$   
我们观测不到的数据

$$\text{若 } z_i = 1, y_i \sim b(1, p)$$

$$\text{若 } z_i = 0, y_i \sim b(1, q)$$

能看的只有  $y_i$

不能看到  $z_i$  的值, 只知道  $z_i$  服从一个这样的分布, 并且  $\pi, p, q$  都不知道.

$$(z_1, y_1), (z_2, y_2), \dots, (z_n, y_n) \quad \theta = (\pi, p, q)^T$$

$(z, y)$  完全数据 (不能看到)  $\rightarrow P(y, z) = P(z) \cdot P(y|z)$

$y$  不完全数据 (能看到) — 观测值

我们想估计的是  $\theta = (\pi, p, q)^T$ , 一般用极大似然估计  
极大似然要写出给定  $\theta$  情况下与观测值的联合概率密度

$$P(y|\theta) = \sum_z P(y, z|\theta) \quad \rightarrow \text{边缘分布} = \pi p^{y_1} (1-p)^{1-y_1} + (1-\pi) q^{y_1} (1-q)^{1-y_1}$$

整理

$$P(y_i|\theta) = \sum_z P(y_i, z|\theta) = \pi p^{y_i} (1-p)^{1-y_i} + (1-\pi) q^{y_i} (1-q)^{1-y_i}$$

$\because$  每个  $y_i$  独立,  $\therefore$  有

$$\prod_{i=1}^n P(y_i|\theta) = \Pi \left[ \sum_z P(y_i, z|\theta) \right] = \Pi [ \quad ]$$

∵ 上式特别复杂, 若要用极大似然法去求, 则要最大化似然函数, 对其求  $p, q$  的导不现实, ∴ 用 EM 算法 (迭代)

★ EM 不直接处理上面<sup>似然函数</sup>的, 要:

将最大化观测数据的似然函数 转化为  
最大化完全数据的似然函数

书上有 2 种解释 { 导出  
推广

$$\Rightarrow p(y, z | \theta) \quad \ln \prod_{i=1}^N p(y_i, z_i | \theta)$$

(我们不知道  $z_i$  的数据)

∴ EM 算法中的 E 步解决了这个问题

E: 把与  $z_i$  有关<sup>的项</sup>  $E(z)$  去替换  $E_i \rightarrow E(z) \rightarrow \theta, y_i$

对不同的  $i$  来说,  $E(z)$  是不变的

如何求  $E(z)$  呢?

∵  $z$  是个随机变量, ∴ 求期望时就要知道  $z$  的分布 (概率密度)

但这个分布取决于  $\theta$  与  $y_i$ , 用迭代法:

1) 给  $\theta$  一个初值 与  $y_i$  一并用来求  $z$  的期望

$\theta^{(i)} \leftarrow$  第  $i$  步给的  $\theta$

2) 将期望代入似然函数, 再最大化似然函数

$$M: \theta^{(i+1)} = \arg \max_{\theta} \ln \prod_{i=1}^N (p_i, E(z) | \theta)$$

求得  $\theta^{(i+1)}$

不断迭代



# EM算法的导出

待估  $\theta$   $Y$  (观测向量)  $Z$  (隐参数)

$$L(\theta) = \ln P(Y|\theta) \quad \text{--- ①}$$

① = ② 的边缘密度之和

$$= \ln \sum_Z P(Y, Z|\theta) \quad \text{--- ②}$$

②  $\rightarrow$  ③ 依据乘法公式

$$= \ln \left[ \sum_Z P(Z|\theta) P(Y|Z, \theta) \right] \quad \text{--- ③}$$

$\theta^{(i)}$   $\leftarrow$  第  $i$  步求出的  $\theta$

$$L(\theta) - L(\theta^{(i)}) = \ln \left[ \sum_Z P(Z|\theta) \cdot P(Y|Z, \theta) \right] - \ln P(Y|\theta^{(i)})$$

分析:  $\ln P_1 P_2 \dots P_N$  好处理

但  $\ln \sum P_1 P_2$  里多了求和号不好处理

$\therefore$  用 Jensen 不等式  $f\left(\sum_i \alpha_i x_i\right) \geq \sum_i \alpha_i f(x_i)$   
 $\downarrow$   $\downarrow$   
 为凸函数  $(0,1)$

要想办法凑出  $\alpha_i$   $\because$  是对  $Z$  求和, 概率求和为 1.

$\therefore$  构造一个  $Z$  的分布

$$= \ln \sum_Z P(Z|Y, \theta^{(i)}) \frac{P(Z|\theta) P(Y|Z, \theta)}{P(Z|Y, \theta^{(i)})} - \ln P(Y|\theta^{(i)})$$

$$\geq \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Z|\theta) P(Y|Z, \theta)}{P(Z|Y, \theta^{(i)})} - \sum_Z P(Z|Y, \theta^{(i)}) \ln P(Y|\theta^{(i)})$$

$$= \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Z|\theta) P(Y|Z, \theta)}{P(Z|Y, \theta^{(i)}) \ln P(Y|\theta^{(i)})}$$

$$\frac{\ln P(Y|\theta^{(i)})}{\ln P(Y|\theta^{(i)})}$$

人为加上,  $\because$  是对  $Z$  求和,  $\therefore$  此项为 1

将  $B(\theta, \theta^{(i)}) = L(\theta^{(i)}) + \uparrow$

$\therefore$  有  $L(\theta) \geq B(\theta, \theta^{(i)})$

最大化  $L(\theta)$  即最大化  $B(\theta, \theta^{(i)})$

$$\theta^{(i+1)} = \arg \max_{\theta} B(\theta, \theta^{(i)})$$

去掉与  $\theta$  无关的

$$= \arg \max_{\theta} \sum_z P(z|Y, \theta^{(i)}) (\ln P(z|\theta) P(Y|z, \theta))$$

$$= \arg \max_{\theta} \underbrace{\sum_z P(z|Y, \theta^{(i)}) \ln P(Y, z|\theta)}_{Q(\theta, \theta^{(i)})}$$

即  $\arg \max Q(\theta, \theta^{(i)}) \leftarrow M$  步



# EM算法及其推广 (如何用EM算法求解混合高斯模型中的参数)

## 高斯混合模型

第k个高斯模型的密度函数

$$P(y|\theta) = \sum_{k=1}^K \alpha_k \varphi(y|\theta_k)$$

待估参数

$\alpha_k$  表示 y 以  $\alpha_k$  的概率来自于第 k 个概率分布

$$\theta = (\alpha_1, \dots, \alpha_K, \mu_1, \sigma_1^2, \dots, \mu_K, \sigma_K^2)$$

$$Y_i = (Y_{i1}, Y_{i2}, \dots, Y_{ik})$$

↑ 取  $\begin{pmatrix} 1, 0, \dots, 0 \\ 0, 1, \dots, 0 \\ \vdots \\ 0, 0, \dots, 1 \end{pmatrix}$  的概率为  $\alpha_1, \alpha_2, \dots, \alpha_K$   
(表示当前的样本来自哪个高斯分布)

$$\therefore P(Y_i, y_i | \theta) = P(Y_i | \theta) \cdot P(y_i | Y_i, \theta)$$

$$= \alpha_1^{Y_{i1}} \alpha_2^{Y_{i2}} \dots \alpha_K^{Y_{ik}} \cdot \varphi(y_i | \theta_1)^{Y_{i1}} \varphi(y_i | \theta_2)^{Y_{i2}} \dots \varphi(y_i | \theta_K)^{Y_{ik}}$$

$$= \prod_{k=1}^K [\alpha_k \varphi(y_i | \theta_k)]^{Y_{ik}}$$

表示第 i 个样本点的完全数据的密度函数

$\therefore$  对所有样本点来说

$$P(Y, y | \theta) = \prod_{j=1}^N \prod_{k=1}^K [\alpha_k \varphi(y_j | \theta_k)]^{Y_{jk}} \quad \text{--- ①}$$

$$= \prod_{k=1}^K \alpha_k^{\sum_{j=1}^N Y_{jk}}$$

$$= \alpha_k^{\sum_{j=1}^N Y_{jk}}$$

(表示在 N 个样本点中, 有多少个是来自第 k 个高斯分布) 用  $n_k$  表示 ( $n_1 + n_2 + \dots + n_K = N$ )

$$\text{①式} \rightarrow \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N [\varphi(y_j | \theta_k)]^{Y_{jk}}$$

将  $\varphi(y_j | \theta_k)$  展开得

$$p(y, r | \theta) = \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N \left[ \frac{1}{\sqrt{2\pi} \sigma_k} \exp\left(-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}\right) \right]^{Y_{jk}}$$

EM 对完全数据的对数函数求解

$$\ln p(y, r | \theta) = \sum_{k=1}^K \left\{ n_k \ln \alpha_k + \sum_{j=1}^N Y_{jk} \left[ \ln \frac{1}{\sqrt{2\pi}} - \ln \sigma_k - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right] \right\} \quad \text{③}$$

E 步: 把上式与 隐变量 有关的项都换成其 期望

$$E n_k = E \left[ \sum_j Y_{jk} \right] = \sum_j E(Y_{jk})$$

$$E(Y_{jk}) = P(Y_{jk} = 1) \quad (Y_{jk} \text{ 要么为 1, 要么为 0})$$

求期望时, 要根据上一步的  $\theta^{(i)}$  与所有观测数据  $y, z$  来求

$$E(Y_{jk} | \theta^{(i)}, y) = \frac{P(Y_{jk} = 1 | \theta^{(i)}, y)}{\quad} \quad \text{用贝叶斯公式求}$$

$$= \frac{P(Y_{jk} = 1, y_j | \theta)}{P(y_j | \theta)} \quad \rightarrow \text{用全概率公式展开}$$

$$= \frac{P(Y_{jk} = 1, y_j | \theta)}{\sum_{k=1}^K P(Y_{jk} = 1, y_j | \theta)} \quad \rightarrow \text{用乘法公式}$$

$$= \frac{\alpha_k \varphi(y_j | \theta_k)}{P(Y_{jk} = 1 | \theta) P(y_j | Y_{jk} = 1, \theta)} \\ = \frac{\alpha_k}{\sum_k P(y_j | Y_{jk} = 1, \theta) P(Y_{jk} = 1 | \theta)}$$

$$\cancel{E(Y_{jk} | \theta^{(i)}, y)} = \frac{\alpha_k^{(i)} \varphi(y_j | \theta_k^{(i)})}{\sum_k \alpha_k^{(i)} \varphi(y_j | \theta_k^{(i)})}$$



$$\begin{array}{c} \text{记为 } z_k \\ \uparrow \\ E(y_{jk} | y, \theta^{(i)}) = \frac{\alpha_k^{(i)} \varphi(y_j | \theta_k^{(i)})}{\sum_k \alpha_k^{(i)} \varphi(y_j | \theta_k^{(i)})} \end{array}$$

代入③式中的  $n_k$  与  $y_{jk}$  得  $Q(\theta, \theta^{(i)})$

将  $z_k$  代入上面③式中得

~~$R(y, \theta)$~~

$$\sum_{k=1}^K (N z_k) \cdot \ln \alpha_k + z_k \sum_{j=1}^N \left[ \ln \frac{1}{\sqrt{2\pi}} - \frac{\ln \sigma_k}{\sigma_k} - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2 \right]$$

即

$$Q(\theta, \theta^{(i)}) = E_z \ln p(y, r | \theta)$$

M步: 要最大化  $Q$  函数, 对 每个  $\theta$  的分量 求导, 让其等  $\bullet 0$

要估计  $(\mu_k, \sigma_k, \alpha_k)$

$$\frac{\partial Q(\theta, \theta^{(i)})}{\partial \mu_k} = 0$$

$$\frac{\partial Q(\theta, \theta^{(i)})}{\partial \sigma_k^2} = 0$$

$$\frac{\partial Q(\theta, \theta^{(i)})}{\partial \alpha_k}$$

$$\sum \alpha_k = 1$$

$$\mu_k^{(i+1)} = \dots$$

$$\sigma_k^{2(k+1)} = \dots$$

$$\alpha_k^{(i+1)} = \dots$$

书上

9.30-9.32

式