

第10章, Hidden Markov Model (HMM)

背景:


概率图 { 有向 - Bayesian Network
无向 - Markov Random Field
(Markov Network)

+time

Dynamic Model { HMM ——— ~~State~~ 离散
Kalman Filter — 连续线性
Particle Filter — 连续非线性

x_i 之间不是 iid
time mixture

HMM



第 10 章 隐马尔可夫模型

背景 隐马尔可夫模型的基本概念

变量多, 用概率图模型 (有向图) 表示变量之间关系

模型参数及符号:

状态集合

观测集合

初始状态概率向量



表示 Y 受到 X 影响



表示看到的变量



表示隐变量

★ 变量可见与否会影响独立性. 例



$$P(X, Z) \neq P(X) \cdot P(Z)$$



$$P(X, Z | Y) = P(X | Y) \cdot P(Z | Y)$$




$$P(X, Z) \neq P(X) P(Z)$$



$$P(X, Z | Y) = P(X | Y) \cdot P(Z | Y)$$

(如不知 Y 值, 需从 Z 推 Y, 再用 Y 推 X, 会有影响)




$$P(X, Z) = P(X) \cdot P(Z)$$



$$P(X, Z | Y) \neq P(Z | Y) \cdot P(X | Y)$$

HMM概率图模型



$$z_t \in \{q_1, \dots, q_N\} \quad I = \{z_1, \dots, z_T\}$$

$$o_t \in \{v_1, \dots, v_M\} \quad O = \{o_1, \dots, o_T\}$$

①

$$\begin{matrix} z_1 = q_1 \\ z_1 = q_2 \\ \vdots \\ z_1 = q_N \end{matrix} \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1N} \\ a_{21} & a_{22} & \dots & a_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{N1} & a_{N2} & \dots & a_{NN} \end{bmatrix} \begin{matrix} (a_{ij} = P(z_2 = q_j | z_1 = q_i)) \\ \text{和为1} (\because a_{ij} \text{ 为条件概率}) \\ \rightarrow A_{N \times N} \text{ (状态之间有向边)} \end{matrix}$$

状态转移关系矩阵

★ (不随时间变化) $\rightarrow z_t, z_{t+1}$

②

$$\begin{matrix} z_1 = q_1 \\ z_1 = q_2 \\ \vdots \\ z_1 = q_N \end{matrix} \begin{bmatrix} b_{1(1)} & b_{1(2)} & \dots & b_{1(M)} \\ b_{2(1)} & b_{2(2)} & \dots & b_{2(M)} \\ \vdots & \vdots & \ddots & \vdots \\ b_{N(1)} & b_{N(2)} & \dots & b_{N(M)} \end{bmatrix} \begin{matrix} (b_{ij(k)} = P(o_t = v_k | z_t = q_j)) \\ \text{和为1} \\ \text{(在时刻 } t \text{ 处于状态 } q_j \text{ 的条件下生成观测 } v_k \text{ 的概率)} \\ B_{N \times M} \\ \text{观测概率矩阵} \end{matrix}$$

z_t, o_t

③

$$\begin{bmatrix} \pi_1 \\ \pi_2 \\ \vdots \\ \pi_N \end{bmatrix} = \begin{bmatrix} P(z_1 = q_1) \\ P(z_1 = q_2) \\ \vdots \\ P(z_1 = q_N) \end{bmatrix}$$

π (初始状态)

$$\lambda = (\pi, A, B)$$

自由参数个数

$N-1$ 表示减去 $(\pi_1 + \pi_2 + \dots + \pi_N)$ 概率和为1这个约束

10.1

两个基本假设: (为了简化模型中变量之间的关系)

齐次马尔科夫性 $P(i_t | i_{t-1}, \dots, i_1) = P(i_t | i_{t-1})$

观测独立假设

三个基本问题 (对应3小节)

概率计算问题 $P(o|\lambda)$

学习问题 $\arg \max_{\lambda} P(o|\lambda)$

预测问题 $P(I|o)$ 可看成让计算机自动标注词性

10.2 概率计算法

计算 $P(o|\lambda)$

1. 直接计算法

$$P(o|\lambda) = \sum_I P(o|I, \lambda) \cdot P(I|\lambda)$$


$$= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

计算复杂度: $O(TN^T)$

$$\begin{aligned} i_1 &\rightarrow N \\ i_2 &\rightarrow N \\ &\vdots \\ i_T &\rightarrow N \end{aligned}$$

2 前向算法

计算复杂度 $O(TN^2)$



输入: 隐马尔可夫模型 λ , 观测序列 O : $\alpha_t(j), \alpha_{t+1}(i)$

输出: 观测序列概率 $P(O|\lambda)$

(1) 初值


$$\alpha_1(i) = \pi_i b_i(O_1), \quad i=1, 2, \dots, N$$

(2) 递推 对 $t=1, 2, \dots, T-1$,

$$\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(O_{t+1}), \quad i=1, 2, \dots, N$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$



3 后向算法

计算复杂度 $O(TN^2)$

输入: 隐马尔可夫模型 λ , 观测序列 O

输出: 观测序列概率 $P(O|\lambda)$

(1) $\beta_T(i) = 1, \quad i=1, 2, \dots, N$

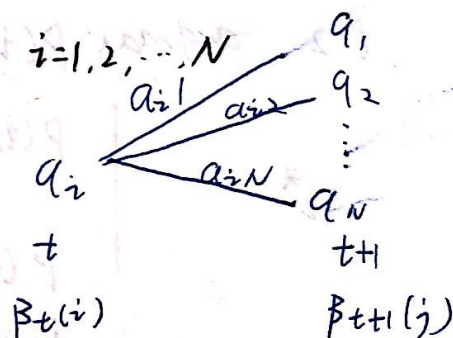
$$\beta_t(i) = P(O_{t+1}, O_{t+2}, \dots, O_T | i_t = q_i, \lambda)$$

(2) 对 $t=T-1, T-2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), \quad i=1, 2, \dots, N$$

(3)

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(O_1) \beta_1(i)$$



10.3 学习算法

估计参数 $\lambda = (\pi, A, B)$

1. 监督学习方法 (知道 O 与 I) P204

2. Baum-welch 算法 (EM 算法)

10.4 预测算法

目标: $\arg \max P(I|O, \lambda)$

1. 近似算法 (得到局部最优, 没考虑状态之间联系)

$$i_t^* = \arg \max_{1 \leq i \leq N} [Y_t(i)], \quad t=1, 2, \dots, T$$

$$Y_t(i) = P(i_t = q_i | O, \lambda)$$

步骤

$$t=1 \quad \arg \max_i P(i_1 = q_i | O, \lambda)$$

$$i_1^* \quad \left\{ \begin{array}{l} P(i_1 = q_1 | O, \lambda) \\ \vdots \\ P(i_1 = q_N | O, \lambda) \end{array} \right.$$


$$I^* = (i_1^*, \dots, i_T^*)$$

$$t=2 \quad \arg \max P(i_2 = q_i | O, \lambda)$$

$$i_2^* \quad \left\{ \begin{array}{l} P(i_2 = q_1 | O, \lambda) \\ \vdots \\ P(i_2 = q_N | O, \lambda) \end{array} \right.$$

2. 维特比算法 (全局最优)

例



相当于用动态规划求概率最大路径 (一个路径对应一个状态序列)

$$\delta_t(i) = P(\underline{i_t = q_i}, i_{t+1}, \dots, i_1, 0_t, 0_{t+1}, \dots, 0_1 | \lambda)$$

argmax
 i_{t-1}, \dots, i_1

$$\therefore P(1, 0) = \underbrace{P(0)}_{\downarrow \text{一直不变}} \cdot P(0|I)$$

\therefore 最大化 $P(1, 0)$ 相当于 $P(0|I)$

前向算法 2 个推导 $\begin{cases} 10.16 & \text{递推公式} \\ 10.17 & \text{终止公式} \end{cases}$

$$\alpha_t(i) = P(o_1, \dots, o_t, i_t = q_i | \lambda)$$

目标是要求 $P(o_1, \dots, o_T | \lambda)$

$$= \sum_{i=1}^N P(o_1, \dots, o_T, i_T = q_i) \rightarrow (\text{边缘概率之和})$$

$$= \sum_{i=1}^N \alpha_T(i) \quad \text{即 10.17}$$

即

$$\begin{matrix} \alpha_1(1) & \alpha_2(1) & \alpha_T(1) \\ \vdots & \vdots & \vdots \\ \alpha_1(N) & \alpha_2(N) & \alpha_T(N) \end{matrix} \rightarrow \dots$$

找两步之间的关系

$$\alpha_t(j) = P(o_1, \dots, o_t, i_t = q_j | \lambda)$$

$$\alpha_{t+1}(i) = P(o_1, \dots, o_t, \underline{o_{t+1}}, \underline{i_{t+1}} = q_i | \lambda) \quad \text{①}$$


②是①的边缘概率

$$= \sum_{j=1}^N P(o_1, \dots, o_t, o_{t+1}, i_{t+1} = q_i, i_t = q_j) \quad \text{②}$$

$$= \sum_{j=1}^N \underbrace{P(o_1, \dots, o_t, i_t = q_j)}_{\alpha_t(j)} \cdot \underbrace{P(o_{t+1} | i_{t+1} = q_i)}_{\rightarrow b_i(o_{t+1})} \cdot \underbrace{P(i_{t+1} = q_i | i_t = q_j)}_{\hookrightarrow a_{ji}}$$

$$= \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1})$$

即 10.16




维特比算法

要:

$$\max P(i_1, \dots, i_T | o_1, \dots, o_T)$$

$$\Rightarrow \max [P(i_1, \dots, i_T, o_1, \dots, o_T)] \cdot P(o_1, \dots, o_T) \xrightarrow{\text{不变}}$$

$$\delta_t(i) = \max_{i_1, \dots, i_{t-1}} P(i_1, \dots, i_{t-1}, \underbrace{i_t=i}_{\text{无约束}}, \underbrace{o_t, \dots, o_T}_{\text{约束}})$$



$$\delta_{t+1}(i) = \arg \max_{i_1, \dots, i_t} P(i_1, \dots, i_t, \underline{i_{t+1}=i}, \underline{o_{t+1}}, \dots, o_T)$$

★

贝尔曼最优原理 (只看 i_t, i_{t+1} 之间的路径不会变)

$$= \arg \max_j \delta_t(j) \cdot P(i_{t+1} | i_t = j) \cdot P(o_{t+1} | i_{t+1} = i)$$

i_{t+1} 只和 i_t 有关
即 a_{ji}

o_{t+1} 只和 i_{t+1} 有关
即 $b_i(o_{t+1})$

$$= \max_j [\delta_t(j) a_{ji}] \underline{b_i(o_{t+1})} \xrightarrow{\text{不变}}$$

对于每个时刻都需记录 N 个不同取值的路径
∴ 之后随着状态改变, 概率最大的路径会改变
当前